Федеральное государственное автономное образовательное
учреждение высшего образования
Университет ИТМО

Факультет программной инженерии и компьютерной техники

Отчёт по лабораторной работе №1 по дисциплине «Низкоуровневое программирование»

Вариант: Документное дерево

Выполнил:
Деев Роман Александрович

Группа: **P33102**

Преподаватели:
Кореньков Ю. Д.

Санкт-Петербург 2022 г.

Задание:

Описание заданий

Задание 1

Создать модуль, реализующий хранение в одном файле данных (выборку, размещение и гранулярное обновление) информации общим объёмом от 10GB соответствующего варианту вида.

Порядок выполнения:

1. Спроектировать структуры данных для представления информации в оперативной памяти
    a. Для порции данных, состоящий из элементов определённого рода (см форму данных), поддержать тривиальные значения по меньшей мере следующих типов: цетырёхбайтовые целые числа и числа с плавающей точкой, текстовые строки произвольной длины, булевские значения
    b. Для информации о запросе
2. Спроектировать представление данных с учетом схемы для файла данных и реализовать базовые операции для работы с ним:
    a. Операции над схемой данных (создание и удаление элементов схемы)
    b. Базовые операции над элементами данных в соответствии с текущим состоянием схемы (над узлами или записями заданного вида)
        i. Вставка элемента данных
        ii. Перечисление элементов данных
        iii. Обновление элемента данных
        iv. Удаление элемента данных
3. Используя в сигнатурах только структуры данных из п.1, реализовать публичный интерфейс со следующими операциями над файлом данных:
    a. Добавление, удаление и получение информации о элементах схемы данных, размещаемых в файле данных, на уровне, соответствующем виду узлов или записей
    b. Добавление нового элемента данных определённого вида
    c. Выборка набора элементов данных с учётом заданных условий и отношений со смежными элементами данных (по свойствам/полями/атрибутам и логическим связям соответственно)
    d. Обновление элементов данных, соответствующих заданным условиям
    e. Удаление элементов данных, соответствующих заданным условиям
4. Реализовать тестовую программу для демонстрации работоспособности решения
    a. Параметры для всех операций задаются посредством формирования соответствующих структур данных
    b. Показать, что при выполнении операций, результат выполнения которых не отражает отношения между элементами данных, потребление оперативной памяти стремится к O(1) независимо от общего объёма фактического затрагиваемых данных
    c. Показать, что операция вставки выполняется за O(1) независимо от размера данных, представленных в файле
    d. Показать, что операция выборки без учёта отношений (но с опциональными условиями) выполняется за O(n), где n – количество представленных элементов данных выбираемого вида
    e. Показать, что операции обновления и удаления элемента данных выполняются не более чем за $O(n*m) > t \rightarrow O(n+m)$, где n – количество представленных элементов данных обрабатываемого вида, m – количество фактически затронутых элементов данных
    f. Показать, что размер файла данных всегда пропорционален количеству фактически размещённых элементов данных
    g. Показать работоспособность решения под управлением ОС семейств Windows и *NIX
5. Результаты тестирования по п.4 представить в составе отчёта, при этом:
    a. В части 3 привести описание структур данных, разработанных в соответствии с п.1
    b. В части 4 описать решение, реализованное в соответствии с пп.2-3
    c. В часть 5 включить графики на основе тестов, демонстрирующие амортизированные показатели ресурсоёмкости по п. 4

Цель

Реализовать базу данных хранящую своё состояние в файле на жёстком диске. Элементы в базе данных должны быть представлены в виде документного дерева. Помимо этого, операции с элементами данных должны удовлетворять ограничениям по времени и памяти.

Идея решения

Основная проблема, с которой придётся бороться — переиспользование высвободившегося места от удалённых элементов, которые могут быть различной длины.

Для борьбы с этим сделаем любые данные, гранулярными: будем записывать их кусками одинаковой длины(далее — чанки), но в каждом из которых будет ссылка на следующий элемент. Получаем, что мы можем разбить весь файл на чанки. Незанятые чанки объединим в связаный список. При записи порции данных возьмём несколько чанков из списка свободных, если список пуст — расширим файл для выделения пачки чанков(страницы). Высвобождаемые чанки возвращаем в список свободных.

Мы получили интерфейс для записи порции данных(кучки байт) в файл, теперь поверх выстоим логику поддержания документного дерева.

Визуализация структуры дерева. Цветами обозначены схема, к которой относится узел

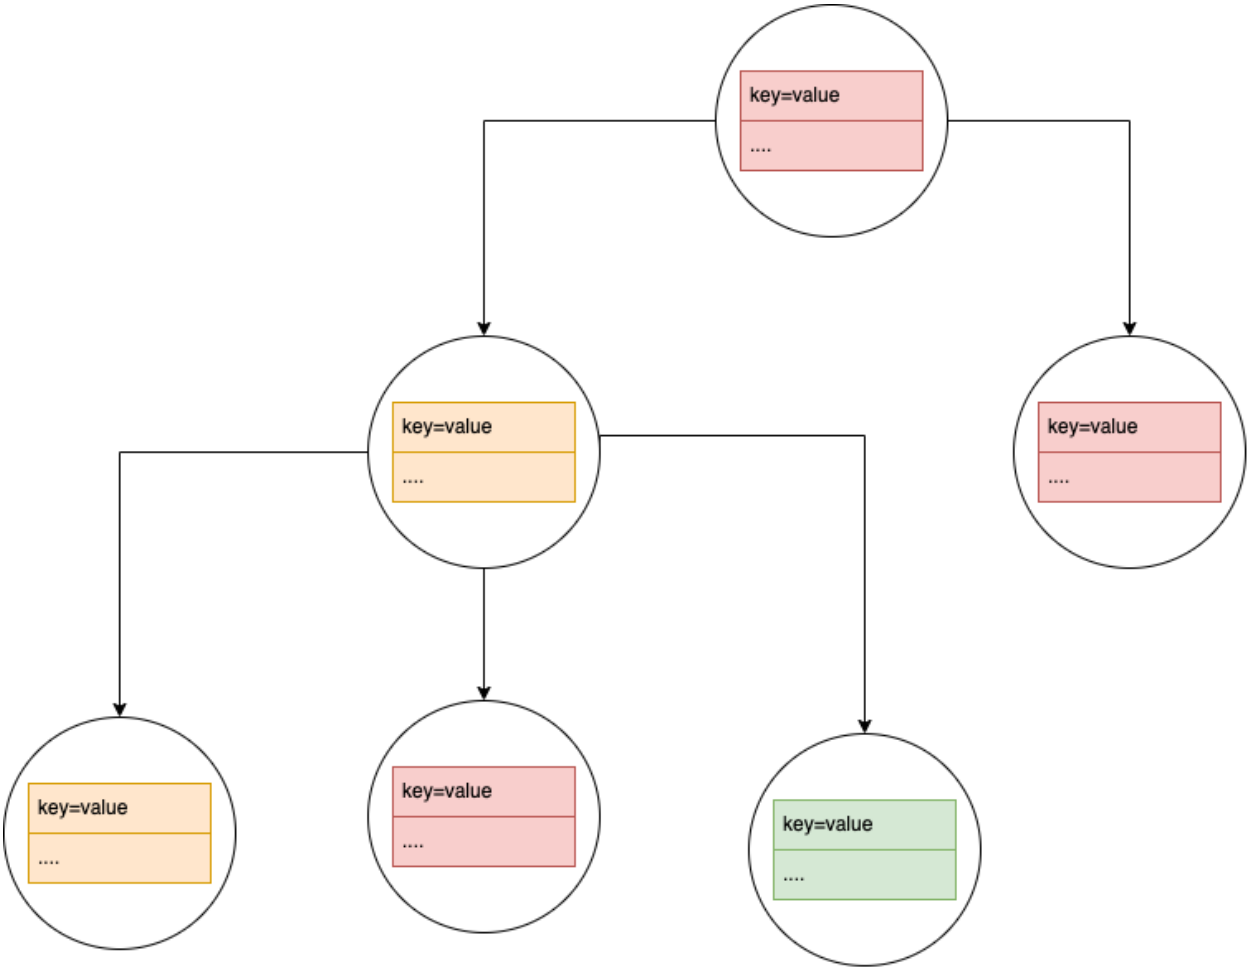

Выделим кучки байт, которые мы ходим записывать:

1. Схемы
2. Узлы дерева
3. Строки

Строки

Любые строки храним в виде указателя(смещения в файле) на первый чаек.

Схемы

Храним в виде связанного списка. Т.е. помимо информации о допустимых ключах и значениях, храним место в файле со следующей схемой.

Узлы дерева

Каждому узлу в дереве при добавлении назначаем id, который под капотом будет указателем на первый чанк узла. Приходящие id от пользователя придётся проверять на валидность.

Введение id даёт нам вставку за O(1) от количества элементов: на вход достаточно принять id предка в дереве. Так как id это указатель место элемента, то найти его для записи нового сына сможем за O(1)

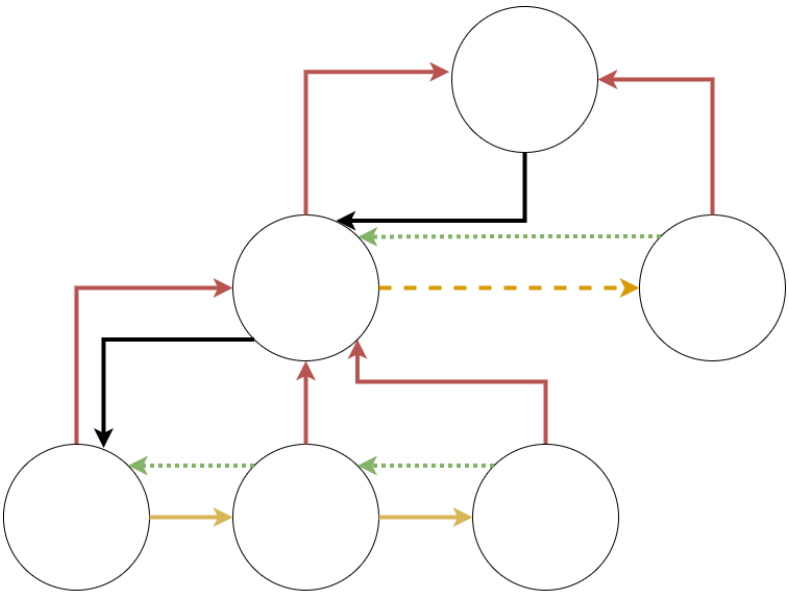

Помимо ссылки на предка(красная) в объекте узла будем хранить ссылку первого сына(чёрная), брата(жёлтая), предыдущего брата(зелёная) и массив ключей/значений. Ключ — ссылка на строку. Значение — union от int32, double, bool, и ссылки на строку. Таким образом обновление значений элемента никак не повлияет на расположение узла в памяти, так как размер элемента не изменяется при таком подходе.

Поиск элементов по условию -- обход дерева O(n)

Для удаления по условию за O(n) придётся реализовать обратный обход (LRN), потому что возможна ситуация, что узел невозможно удалить, пока не удалены его потомки. Удаление конкретного элемента занимает O(1) так как известна его позиция в файле и все ссылающиеся на него элементы.

Аспекты реализации

Главный класс — Database.

Через его публичные методы происходит выполнение требуемых операций с деревом. Принимаемые аргументы и возвращаемые значение описаны в Query.h.

Для чтения записи произвольные байтов Database есть объект FileInterface с методами Write/Read

Методы содержащие в названии BytesBatch служат для записи/чтения/удаления чанков объектов.

Остальные методы -- вспомогательные для публичных методов и итераторов по схемам и по дереву.

Далее можно выделить три типа классов:

1. Классы объектов базы отдаваемые пользователю: Element, Schema, ...

2. Упакованные классы служащие которые будут записываться BytesBatch-методами: raw_*, ...

3. Промежуточные между 1 и 2: ElementBox, SchemaBox. С ними взаимодействуют вспомогательные методы

Результаты

Код реализованного модуля лежит в папке llp.

Модуль представляет собой cmake INTERFACE, пример использования можно найти в папке `examples`.

Больше примеров работы с публичными методами можно найти в папке `llp/tests.` В файле `bench.cpp` код бенчмарков.

Сборка и тестирование поддержаны для ubuntu(g++, clang), macos(clang), windows(msbuild, mingw32)

Для сборки у себя:

```
git clone https://github.com/deevroman/low-level-programming-labs.git &&
cd low-level-programming-labs
# сборка модуля
cmake -B llp/build -DCMAKE_BUILD_TYPE=Release llp
cmake --build llp/build --config Release
# сборка примера
cmake -B examples/build -DCMAKE_BUILD_TYPE=Release examples
cmake --build examples/build --config Release
# запуск
./examples/build/bin/*/*
```

Бинарник после запуска должен вывести:

```
Usage: ./example path/to/file⏎
```

При проблемах обратитесь к файлу `.github/workflows/cmake.yml` и к логам GitHub Action, в котором выполняются шаги описанные в файле.

Ресурсоёмкость

Слева результаты в GitHub Action, справа — на своём компьютере.

Время последовательной вставки 10 тысяч элементов:

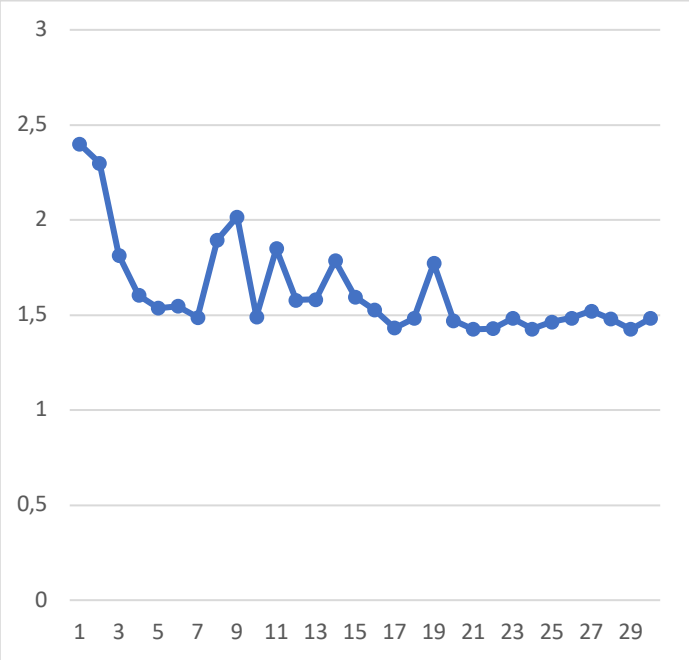

Вставка O(1)

Время выборки элементов по условию, после вставки 10 тысяч новых:

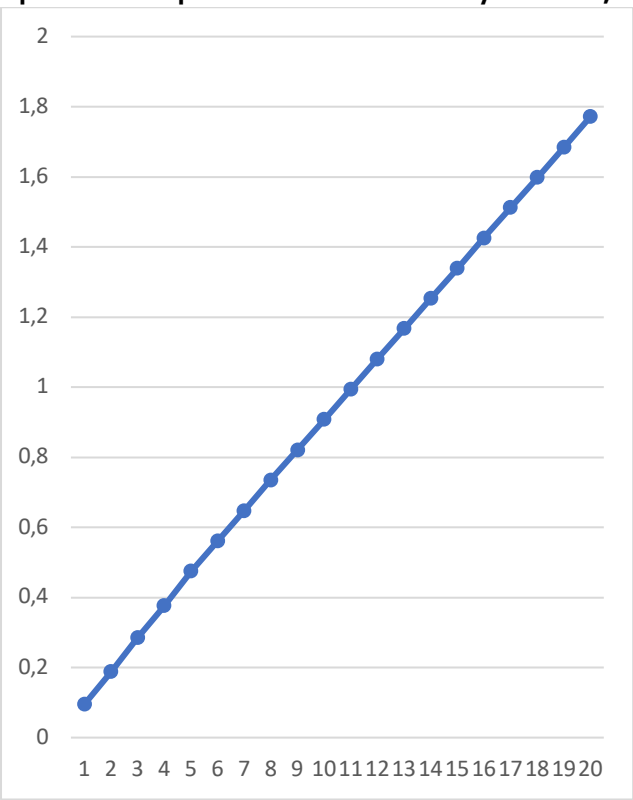

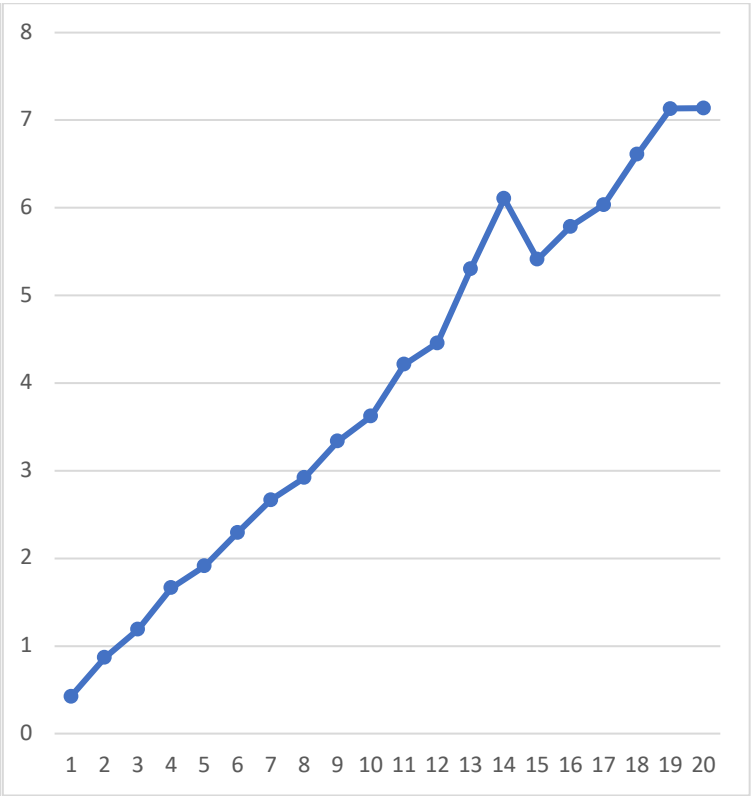

Поиск O(n)

Время удаления 5 тысяч элементов после увеличения элементов на 10 тысяч

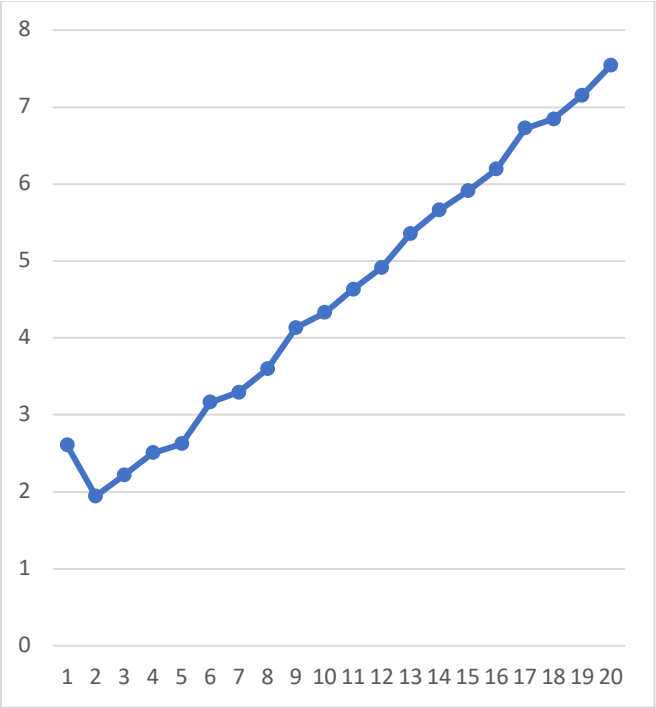

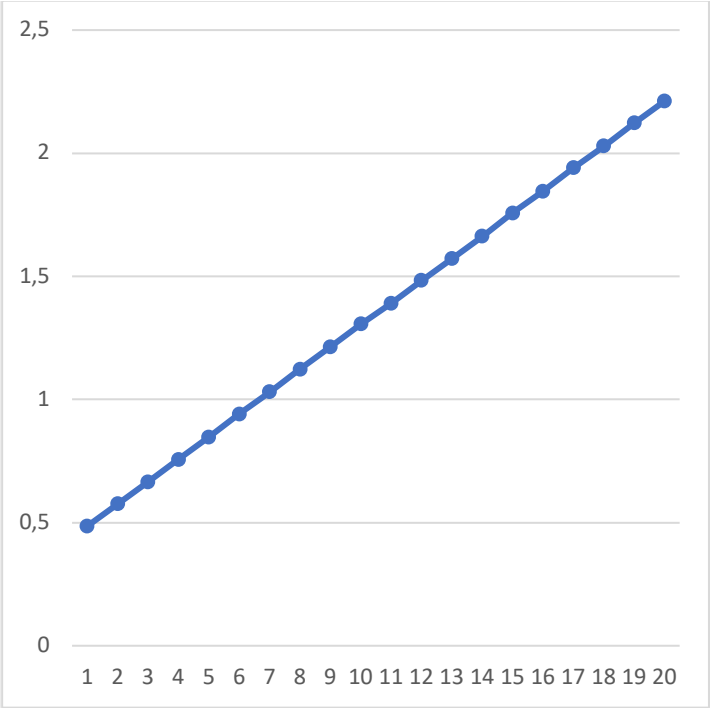

Удаление O(n)

Размер файла в байтах после вставки 100 тысяч элементов, удаления половины, и продолжения вставки

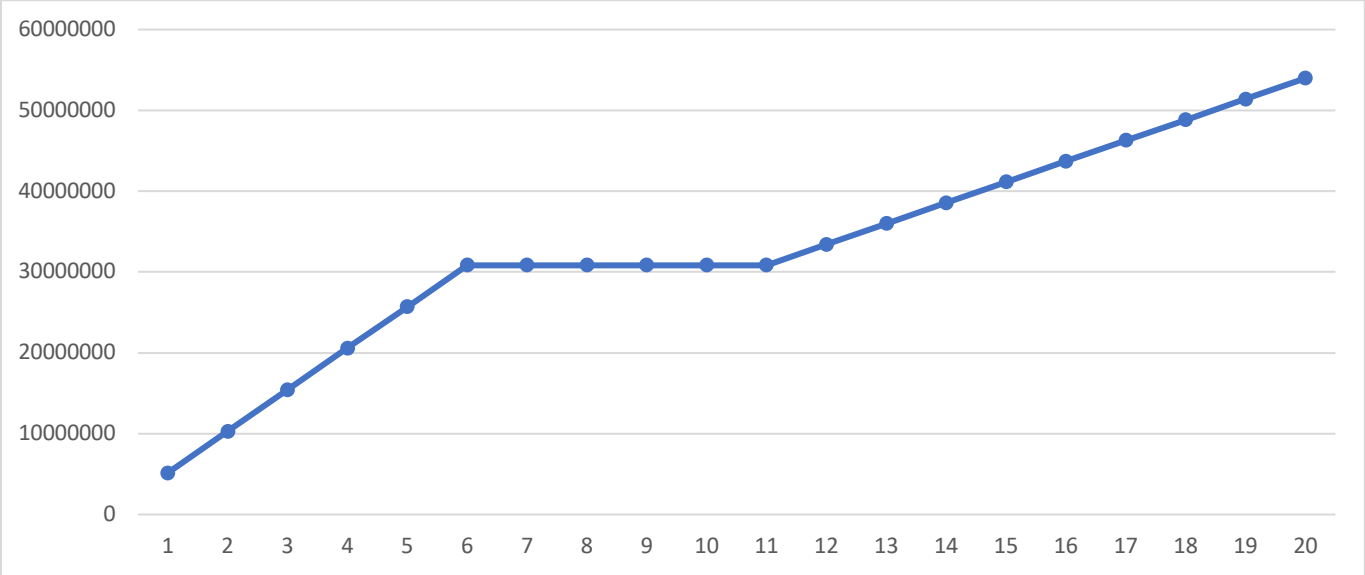

Освобождаемое пространство переиспользуется.

Выводы:

- Реализовал хранение документного дерева в файле
- Провёл замеры времени работы
- Изучил фреймворк GoogleTest
- Попрактиковался в сборке на под разные платформы с помощью CMake и запуске тестов на разных платформах в GitHub Actions
- Изучил средства просмотра бинарных файлов и кастомные визуализаторы в отладчиках
- ~~Возненавидел Windows и g++~~